

Modelos Estadísticos de Pronóstico

Familia ARIMA

Sergio A. Cantillo
sacantillo@uao.edu.co

Facultad de Ingeniería y Ciencias Básicas
Universidad Autónoma de Occidente

Agenda

1 Modelos Autoregresivos (AR)

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA
 - Identificación de Componentes Estacionales
 - Casos de Estudio

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA
 - Identificación de Componentes Estacionales
 - Casos de Estudio
- 7 Modelos ARIMAX

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA
 - Identificación de Componentes Estacionales
 - Casos de Estudio
- 7 Modelos ARIMAX
- 8 Resumen

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA
 - Identificación de Componentes Estacionales
 - Casos de Estudio
- 7 Modelos ARIMAX
- 8 Resumen

Modelo AR(p): Definición Matemática

Definition

Un proceso $\{Y_t\}$ sigue un modelo **Autoregresivo de orden p**, AR(p), si:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t$$

Componentes:

- c : constante (intercepto)
- $\phi_1, \dots, \phi_p$: parámetros AR
- $\epsilon_t \sim WN(0, \sigma^2)$: ruido blanco
- p : orden del modelo (número de lags)

Interpretación:

- Regresión del presente sobre el pasado
- Auto = consigo mismo
- Depende linealmente de sus propios valores pasados
- Memoria de p periodos

Parámetros y Orden del Modelo AR

- p determina cuántos valores pasados se usan
- Mayor p = más flexible pero más parámetros
- Trade-off entre ajuste y complejidad
- Típicamente: $p \in \{1, 2, 3, 4\}$

- **Coeficientes:** $\phi_1, \phi_2, \dots, \phi_p$
- **Constante:** c (opcional)
- **Varianza del error:** σ^2

Total: $p + 2$ parámetros (o $p + 1$ sin constante)

Selección de p

- Gráfico PACF (corte abrupto en lag p)
- Criterios de información (AIC, BIC)
- Validación cruzada

Ejemplos: AR(1) y AR(2)

AR(1)

$$Y_t = c + \phi Y_{t-1} + \epsilon_t$$

Casos especiales:

- $\phi = 0$: Ruido blanco
- $\phi = 1, c = 0$: Random walk
- $0 < \phi < 1$: Reversión a media
- $-1 < \phi < 0$: Oscilación
- $|\phi| > 1$: No estacionario (explosivo)

Media incondicional:

$$E[Y_t] = \frac{c}{1 - \phi} \quad \text{si } |\phi| < 1$$

AR(2)

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t$$

Puede generar:

- Comportamiento oscilatorio
- Ciclos pseudo-periódicos
- Patrones más complejos

Condiciones de estacionaridad:

- $\phi_2 + \phi_1 < 1$
- $\phi_2 - \phi_1 < 1$
- $|\phi_2| < 1$


Condiciones de Estacionaridad

Condición General para AR(p)

Un proceso AR(p) es estacionario si todas las raíces del polinomio característico:

$$\Phi(z) = 1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p = 0$$

están **fuera del círculo unitario** en el plano complejo ($|z| > 1$).



Identificación de Modelos AutoRegresivos (AR)


Proceso AR(p)

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t$$


Características:

- **ACF:** Decae exponencialmente o con patrón sinusoidal amortiguado
- **PACF:** Corte abrupto después del lag p

Ejemplo: AR(2)



Decae gradualmente



Corte en lag 2

Estimación de Parámetros: Maximum Likelihood Estimation (MLE)

Asumiendo $\epsilon_t \sim N(0, \sigma^2)$, la log-verosimilitud es:

$$\log L(\phi, \sigma^2 | \mathbf{Y}) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{t=p+1}^n \epsilon_t^2$$

donde $\epsilon_t = Y_t - c - \phi_1 Y_{t-1} - \dots - \phi_p Y_{t-p}$

Proceso:

- 1 Maximizar $\log L$ respecto a $\phi_1, \dots, \phi_p, c, \sigma^2$
- 2 Usar optimización numérica (Newton-Raphson, BFGS)
- 3 Obtener estimadores $\hat{\phi}_i, \hat{c}, \hat{\sigma}^2$

- Asintóticamente eficiente
- Errores estándar automáticos
- Intervalos de confianza y tests de hipótesis

Estimación de Parámetros: Ordinary Least Squares (OLS)

Minimizar la suma de cuadrados de los residuales:

$$SSE = \sum_{t=p+1}^n (Y_t - c - \phi_1 Y_{t-1} - \dots - \phi_p Y_{t-p})^2$$

Forma matricial:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\phi} + \boldsymbol{\epsilon}$$

donde $\mathbf{Y} = [Y_{p+1}, \dots, Y_n]^T$, $\mathbf{X}$ contiene los lags, $\boldsymbol{\phi} = [c, \phi_1, \dots, \phi_p]^T$

Estimador OLS: $\hat{\boldsymbol{\phi}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$

Ventajas OLS:

- Simple y rápido
- No requiere normalidad
- Fórmula cerrada

Desventajas:

- Menos eficiente que MLE
- Para AR, $\text{MLE} \approx \text{OLS}$

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA
 - Identificación de Componentes Estacionales
 - Casos de Estudio
- 7 Modelos ARIMAX
- 8 Resumen

Modelo MA(q): Definición y Conceptos

Un proceso $\{Y_t\}$ sigue un modelo de **Media Móvil de orden q**, MA(q), si:

$$Y_t = \mu + \epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2} + \cdots + \theta_q\epsilon_{t-q}$$

Componentes:

- μ : media del proceso
- $\theta_1, \dots, \theta_q$: parámetros MA
- $\epsilon_t \sim WN(0, \sigma^2)$: errores
- q : orden (memoria de errores)

Interpretación:

- Combinación lineal de errores
- No depende de Y_{t-i} directamente
- “Suaviza” shocks aleatorios
- Memoria limitada a q periodos

Diferencia clave con AR

- AR: regresión sobre valores pasados de Y_t
- MA: regresión sobre errores pasados ϵ_t
- MA siempre es estacionario por definición

Condiciones de Invertibilidad

Un proceso MA(q) es **invertible** si puede expresarse como un AR(∞):

$$Y_t = \mu + \sum_{j=1}^{\infty} \pi_j Y_{t-j} + \epsilon_t$$

Es decir, que todas las raíces del polinomio deben estar **fuera del círculo unitario** ($|z| > 1$):

$$\Theta(z) = 1 + \theta_1 z + \theta_2 z^2 + \dots + \theta_q z^q = 0$$

¿Por qué importa?

- Garantiza unicidad de parámetros
- Permite estimación consistente
- Similar a estacionaridad en AR
- Análogo conceptual pero para MA

Identificación de Modelos de Media Móvil (MA)


Proceso MA(q)

$$Y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q}$$


Características:

- **ACF:** Corte abrupto después del lag q
- **PACF:** Decae gradualmente (exponencial o sinusoidal)

Ejemplo: MA(1)



Corte en lag 1



Decae gradualmente

Diferencias entre AR y MA

Aspecto	AR(p)	MA(q)
Definición	Regresión sobre Y_{t-i}	Regresión sobre ϵ_{t-i}
Estacionaridad	Condiciónal (raíces fuera)	Siempre estacionario
Invertibilidad	Siempre invertible	Condiciónal (raíces fuera)
ACF	Decae gradual	Corte en lag q
PACF	Corte en lag p	Decae gradual
Memoria	Infinita (teóricamente)	Finita (q pasos)
Interpretación	Valores pasados	Shocks pasados
Estimación	MLE, OLS directo	Solo MLE práctico

Complementariedad

AR y MA son “duales”:

- Lo que AR hace en PACF, MA lo hace en ACF
- Lo que AR hace en ACF, MA lo hace en PACF
- Combinados (ARMA) son más poderosos

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA
 - Identificación de Componentes Estacionales
 - Casos de Estudio
- 7 Modelos ARIMAX
- 8 Resumen

Combinación AR + MA

Definition

Un proceso $\{Y_t\}$ sigue un modelo **ARMA(p,q)** si combina componentes AR y MA:

$$Y_t = c + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}$$

Forma compacta con operadores

$$\Phi(L)Y_t = c + \Theta(L)\epsilon_t$$

donde:

- $\Phi(L) = 1 - \phi_1 L - \cdots - \phi_p L^p$ (polinomio AR)
- $\Theta(L) = 1 + \theta_1 L + \cdots + \theta_q L^q$ (polinomio MA)
- L es el operador de rezago: $LY_t = Y_{t-1}$

¿Por qué utilizar modelos ARMA? (I)

Ventajas principales

- **Parsimonia:** Menor número de parámetros
- **Flexibilidad:** Captura patrones complejos
- **Eficiencia:** Representación compacta de procesos
- Mejor equilibrio entre ajuste y complejidad

Desafíos en la identificación

- Identificación más compleja
- ACF y PACF decaen simultáneamente
- No presentan cortes abruptos
- Requiere mayor expertise

¿Por qué utilizar modelos ARMA? (II)

Estrategias de solución

- Criterios de información (AIC, BIC)
- Búsqueda en rejilla (grid search)
- Metodología Box-Jenkins
- Algoritmos auto-ARIMA

Ejemplo ilustrativo

Un proceso $MA(\infty)$ puede aproximarse con $ARMA(1,1)$:

$$Y_t = \phi Y_{t-1} + \epsilon_t + \theta \epsilon_{t-1}$$

- 2 parámetros vs infinitos
- Representación más eficiente

Identificación del Orden (p,q): Patrones

- Ambas funciones (ACF y PACF) **decaen gradualmente**
- No hay corte abrupto claro en ninguna
- Puede haber comportamiento oscilatorio
- Difícil identificación visual

Modelo	ACF	PACF	Identificación
AR(p)	Decaen gradual	Corte en p	PACF determina p
MA(q)	Corte en q	Decaen gradual	ACF determina q
ARMA(p,q)	Decaen gradual	Decaen gradual	AIC/BIC necesario

Estrategia Práctica

- 1 Graficar ACF/PACF, si ambas decaen $\Rightarrow$ considerar ARMA
- 2 Probar múltiples combinaciones (p,q)
- 3 Seleccionar con AIC/BIC

Criterios de Información: AIC

$$AIC = -2\log(L) + 2k$$

Componentes:

- $\log(L)$: log-verosimilitud del modelo (mide ajuste)
- k : número total de parámetros estimados
- $2k$: penalización por complejidad

Interpretación:

- Menor AIC $\Rightarrow$ Mejor modelo
- Balance entre ajuste (primer término) y parsimonia (segundo término)
- Tiende a seleccionar modelos ligeramente más complejos

Para ARMA(p,q): $k = p + q + 2$ (coeficientes + constante + σ^2)

- ARMA(1,1): $k = 4$, ARMA(2,1): $k = 5$

Criterios de Información: BIC

$$BIC = -2\log(L) + k\log(n)$$

Diferencia con AIC: penaliza más a medida que crece n

AIC:

- Mejor para predicción
- Penalización fija ($2k$)
- Puede sobre-ajustar
- Más permisivo

BIC:

- Mejor para inferencia
- Penalización crece con n
- Tiende a parsimonia
- Más conservador

Regla General

- Si ambos coinciden $\Rightarrow$ fuerte evidencia
- Si difieren $\Rightarrow$ considerar objetivo (predicción vs interpretación)

Principio de Parsimonia

Navaja de Occam aplicada a Series de Tiempo

Entre modelos con ajuste similar, preferir el más simple

Razones:

- Menor riesgo de overfitting
- Más fácil interpretación
- Estimación más estable
- Predicciones más robustas
- Menor varianza de parámetros

En la práctica:

- Evitar órdenes altos ($p, q > 3$)
- No usar ARMA(5,5) si ARMA(1,1) funciona
- Balance entre ajuste y complejidad
- Criterios penalizan complejidad

Ejemplo

- ARMA(1,1): 2 parámetros $\Rightarrow$ Simple, preferible
- ARMA(3,2): 5 parámetros $\Rightarrow$ Solo si mejora sustancialmente
- AR(10): 10 parámetros $\Rightarrow$ Probablemente sobre-ajuste


Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins**
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA
 - Identificación de Componentes Estacionales
 - Casos de Estudio
- 7 Modelos ARIMAX
- 8 Resumen

Metodología Box-Jenkins

Enfoque sistemático para modelado ARMA (Box & Jenkins, 1970)

Proceso iterativo de 4 pasos para identificar, estimar y validar modelos de series temporales



Iterativo

Si el diagnóstico falla, se vuelve al paso 1 con nueva información

Sistemático

Cada paso proporciona información para mejorar el modelo

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA
 - Identificación de Componentes Estacionales
 - Casos de Estudio
- 7 Modelos ARIMAX
- 8 Resumen

Componente de Integración (d)

La letra **I** en ARIMA significa **Integrated** (Integrado). El parámetro d indica cuántas veces se debe diferenciar la serie para hacerla estacionaria.

Diferenciación de orden d :

- $d = 0$: Sin diferenciación (ARMA)
- $d = 1$: Primera diferencia
 $\nabla Y_t = Y_t - Y_{t-1}$
- $d = 2$: Segunda diferencia
 $\nabla^2 Y_t = \nabla Y_t - \nabla Y_{t-1}$
- $d \geq 3$: Muy raro en la práctica

Selección de d

- Verificar estacionaridad con test ADF
- Si no estacionaria: $d = 1$
- Si aún no estacionaria: $d = 2$
- Generalmente $d \in \{0, 1, 2\}$
- Evitar sobre-diferenciación

Relación con ARIMA

$\text{ARIMA}(p, d, q) = \text{ARMA}(p, q)$ sobre $\nabla^d Y_t$

Definición Completa de ARIMA(p,d,q)

Un proceso $\{Y_t\}$ sigue un modelo ARIMA(p,d,q) si después de diferenciar d veces, la serie resultante $W_t = \nabla^d Y_t$ sigue un ARMA(p,q):

$$W_t = c + \phi_1 W_{t-1} + \cdots + \phi_p W_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}$$


$$\Phi(L)(1-L)^d Y_t = c + \Theta(L)\epsilon_t$$

Casos especiales


- ARIMA(p,0,q) = ARMA(p,q) (sin integración)
- ARIMA(0,1,0) = Random Walk (paseo aleatorio)
- ARIMA(0,1,0) con $c > 0$ = Random Walk con drift
- ARIMA(p,1,0) = AR(p) diferenciado

Ejemplo: De Serie No Estacionaria a ARIMA

Original: Y_t
(No estacionaria)



Primera diferencia: $\nabla Y_t = Y_t - Y_{t-1}$
(Estacionaria)



Ajustar ARMA(p,q) a esta serie diferenciada

Resultado

Si diferenciamos y obtenemos una serie estacionaria que sigue ARMA(1,1), entonces la serie original sigue ARIMA(1,1,1).

Identificación de modelos ARIMA(p,d,q)

Paso 1: Determinar d

- 1 Graficar serie original: ¿tiene tendencia?
- 2 Test ADF: si $p > 0.05 \Rightarrow$ no estacionaria
- 3 Diferenciar una vez: ∇Y_t
- 4 Test ADF nuevamente: si $p < 0.05 \Rightarrow d = 1$
- 5 Si aún no estacionaria: diferencias segunda vez


Paso 2: Determinar p y q

Una vez que la serie es estacionaria:

- 1 Graficar ACF y PACF de la serie diferenciada
- 2 PACF corte en lag $p \Rightarrow$ identificar p
- 3 ACF corte en lag $q \Rightarrow$ identificar q
- 4 Si ambas decaen $\Rightarrow$ probar múltiples ARMA(p,q)

$$p \in \{0, 1, 2, 3\} \quad d \in \{0, 1, 2\} \quad q \in \{0, 1, 2, 3\}$$

Metodología Box-Jenkins aplicada a ARIMA



Iteración

Si diagnóstico falla: volver a identificación, probar otros (p, d, q)

Auto-ARIMA: Búsqueda Automática

Algoritmo que automatiza la selección de parámetros ARIMA(p, d, q):

- 1 Ejecuta test ADF para determinar d
- 2 Realiza grid search sobre múltiples (p, q)
- 3 Selecciona modelo con menor AIC/BIC
- 4 Evita configuraciones problemáticas

Ventajas

- Rápido y sistemático
- Encuentra buenos modelos automáticamente
- No requiere experiencia del usuario
- Usa mejores prácticas

Limitaciones

- Puede no encontrar óptimo global
- Ignora conocimiento de dominio
- Mejor usarlo como punto de partida
- Validar resultados siempre

Diagnóstico de Residuales en ARIMA

Los residuales válidos $\{\hat{\epsilon}_t\}$ deben ser:

- 1 **Ruido Blanco:** Media = 0, Varianza constante
- 2 **No correlacionados:** ACF/PACF sin picos significativos
- 3 **Normales:** Test Jarque-Bera $p > 0.05$
- 4 **Sin patrón temporal:** Aleatorios alrededor de 0

Tests Clave

- **Ljung-Box:** $p > 0.05$ (sin autocorr)
- **Jarque-Bera:** $p > 0.05$ (normalidad)
- **ACF/PACF:** Barras dentro de bandas
- Q-Q plot (puntos sobre línea diagonal)
- Histograma (debe parecer normal)

Si falla diagnóstico

- Residuales correlacionados: modelo incompleto
- No normales: transformación de datos
- Patrón temporal: falta estructura
- Probar otro (p,d,q)

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA**
 - Identificación de Componentes Estacionales
 - Casos de Estudio
- 7 Modelos ARIMAX
- 8 Resumen

Notación SARIMA(p,d,q)(P,D,Q) s

SARIMA = Seasonal ARIMA. Modelo que maneja tanto componentes regulares como estacionales s .

Componentes no estacionales

- (p, d, q) : como en ARIMA
- p : orden autoregresivo regular
- d : diferenciación regular
- q : orden media móvil regular

Componentes estacionales


- (P, D, Q) : componente seasonal
- P : orden AR estacional
- D : diferenciación estacional
- Q : orden MA estacional

Ejemplo

SARIMA(1,1,1)(1,1,1) $_{12}$ para datos mensuales:

- $(1, 1, 1)$: AR(1), diferenciación 1 vez, MA(1) — componente regular
- $(1, 1, 1)_{12}$: SAR(1), diferenciación estacional, SMA(1) con período 12

Identificación de Componentes Estacionales



Patrones Estacionales en ACF/PACF

En lugar de mirar solo lags $1, 2, 3, \dots$, se revisan lags estacionales: $s, 2s, 3s, \dots$

Datos mensuales ($s = 12$)

ACF:

- Lags 1–11: comportamiento regular (AR/MA)
- Lag 12: pico fuerte (SAR/SMA)
- Lags 13–23: repetición
- Lag 24: otro pico (patrón anual)

Interpretación

- ACF decae en lags $s, 2s, \dots$: tendencia estacional
- PACF corte en lag s : $P = 1$
- ACF corte en lag s : $Q = 1$
- Ambas decaen: SARIMA con múltiples P, Q

Regla

Si ves picos en intervalos regulares de s lags $\Rightarrow$ componente estacional presente

Casos de Uso de SARIMA

Ventas Retail

- Estacionalidad semanal y anual (navidad)
- SARIMA(1,1,1)(1,1,1)₁₂ típico

Pasajeros Aéreos

- SARIMA(0,1,1)(0,1,1)₁₂ (modelo clásico)
- Crecimiento + patrón estacional fuerte

Temperatura

- Estacionalidad anual (invierno/verano)
- SARIMA con $s = 12$ (datos mensuales)

Consumo de Energía

- Estacionalidad diaria y anual
- SARIMA con $s = 24$ (horas) o $s = 365$ (días)

Diagnóstico Exhaustivo de Residuales

- ➊ **Visualización temporal:** ¿aleatorios alrededor de 0?
- ➋ **Histograma:** ¿forma aproximadamente normal?
- ➌ **ACF/PACF:** ¿todas las barras dentro de bandas?
- ➍ **Ljung-Box:** $p > 0.05$? (sin autocorrelación)
- ➎ **Normalidad:** Jarque-Bera $p > 0.05$?
- ➏ **Homogeneidad:** ¿varianza constante?
- ➐ **Independencia:** ¿sin patrones?
- ➑ **Media:** ¿cercana a 0?

- Si TODOS los tests pasan: modelo válido ✓
- Si Ljung-Box falla: autocorrelación residual (modelo incompleto)
- Si normalidad falla: considerar transformación
- Si hay patrón visual: revisar (p,d,q)

Decisión

- OK: usar para pronóstico
- NO OK: volver a identificación

Casos de Estudio: Selección de Parámetros

Caso 1: Tendencia

- **Síntomas:** Gráfico va hacia arriba/abajo
- **ADF:** $p > 0.05$
- **Acción:** $d = 1$
- **Resultado:** ARIMA($p, 1, q$)

Caso 3: Tendencia + Estacionalidad

- **Síntomas:** Crecimiento + patrón cíclico
- **Acción:** Ambas diferenciaciones
- **Resultado:** SARIMA($p, 1, q$)($P, 1, Q$) s
- **Ejemplo:** SARIMA(1,1,1)(1,1,1) $_{12}$

Caso 2: Estacionalidad

- **Síntomas:** Patrón repetitivo cada s períodos
- **ACF:** Picos en lags $s, 2s, 3s, \dots$
- **Acción:** $D = 1$ (diferenciación estacional)
- **Resultado:** SARIMA(p, d, q)($P, 1, Q$) s


Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA
 - Identificación de Componentes Estacionales
 - Casos de Estudio
- 7 Modelos ARIMAX**
- 8 Resumen

Jerarquía de Modelos Box-Jenkins

Extensiones naturales de ARIMA

Cada capa agrega la capacidad de modelar un patrón adicional:



ARIMAX = ARIMA + variables externas ($\mathbf{X}$)

SARIMAX es el modelo más general de la familia

ARIMAX — Definición Matemática

Definition

Un proceso $\{Y_t\}$ sigue un modelo **ARIMAX**(p,d,q) si, tras diferenciar d veces:

$$Y_t = \underbrace{c + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}}_{\text{componente ARIMA}} + \underbrace{\beta_1 X_{1,t} + \beta_2 X_{2,t} + \cdots + \beta_k X_{k,t}}_{\text{variables exógenas}}$$

Nuevos componentes:

- $X_{j,t}$: variable exógena j en el instante t
- β_j : impacto de X_j sobre Y_t (coeficiente de regresión)
- k : número de variables exógenas

Total de parámetros: $p + q + k + 2$

Ejemplos de $X_{j,t}$

- Temperatura promedio mensual
- Indicador de feriado (0/1)
- Gasto en publicidad
- Precio del insumo o del competidor
- Tipo de cambio, tasa de interés

ARIMAX — Supuesto Fundamental

Condición indispensable para pronosticar

Los valores **futuros** de las variables exógenas deben ser conocidos o pronosticados con suficiente precisión antes de hacer el pronóstico de Y_t .

Variable exógena	¿Conocida de antemano?	¿Recomendada?
Mes del año, día de la semana	Siempre	✓
Días feriados, eventos fijos	Siempre	✓
Temperatura (pronóstico climático)	Con incertidumbre	✓ parcial
Precio del insumo del próximo mes	No	✗
Indicadores macroeconómicos futuros	No	✗

Regla Práctica

Si el error al pronosticar X es alto, el error final de ARIMAX puede ser **mayor** que el de un ARIMA sin variables exógenas. Siempre validar con validación cruzada temporal.

ARIMAX — Identificación e Interpretación

Selección de variables X

- 1 Verificar correlación con Y_t (análisis previo)
- 2 Confirmar que X no es redundante con la estacionalidad ya capturada
- 3 Evaluar disponibilidad futura de X
- 4 Comparar AIC/BIC: ARIMA vs ARIMAX
- 5 Validar con RMSE en datos de prueba

Interpretación de $\hat{\beta}_j$

- $\hat{\beta}_j > 0$: al aumentar X_j en 1 unidad, Y_t aumenta $\hat{\beta}_j$
- $\hat{\beta}_j < 0$: relación inversa
- $\hat{\beta}_j \approx 0$: X_j no aporta información significativa
- Verificar signo y magnitud con la teoría del dominio

Advertencia: multicolinealidad estacional

Si X tiene el mismo período estacional que Y (ej. temperatura mensual vs ventas mensuales), parte de su información ya está capturada por la componente estacional del SARIMA. La mejora de ARIMAX sobre SARIMA puede ser marginal o nula.

Agenda

- 1 Modelos Autoregresivos (AR)
- 2 Modelos de Media Móvil (MA)
- 3 Modelos ARMA(p,q)
- 4 Metodología Box-Jenkins
- 5 Modelos ARIMA(p,d,q)
 - Identificación de componentes (p,d,q)
 - Metodología Box-Jenkins aplicada a ARIMA
 - Auto-ARIMA
 - Diagnóstico de Residuales en ARIMA
- 6 Modelos SARIMA
 - Identificación de Componentes Estacionales
 - Casos de Estudio
- 7 Modelos ARIMAX
- 8 **Resumen**

Tabla Resumen: ARIMA vs SARIMA

Característica	ARIMA(p,d,q)	SARIMA(p,d,q)(P,D,Q)s
Maneja tendencia	Sí (via d)	Sí (via d)
Maneja estacionalidad	No	Sí (via P, D, Q, s)
Complejidad	Moderada	Alta
Parámetros	$p + q + 2$	$p + q + P + Q + 2$
Mejor para	Series simples	Series con ciclos
Auto-ARIMA	Sencillo	Requiere s conocido
Interpretabilidad	Alta	Moderada

Flujo de Decisión

Serie $\rightarrow$ ¿Estacional? $\rightarrow$ No: ARIMA(p,d,q) Sí: SARIMA(p,d,q)(P,D,Q)s ¿Variables
externas? $\rightarrow$ ARIMAX / SARIMAX

Referencias

-  Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5th ed.). Wiley.
-  Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press.
-  Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts.
-  Peixeiro, M. (2022). *Time Series Forecasting in Python*. Manning Publications.
-  Shumway, R. H., & Stoffer, D. S. (2017). *Time Series Analysis and Its Applications* (4th ed.). Springer.