

Modelos Clásicos de Pronóstico

Suavizado Exponencial, Theta y Prophet

Sergio A. Cantillo
sacantillo@uao.edu.co

Facultad de Ingeniería y Ciencias Básicas
Universidad Autónoma de Occidente

Agenda

1 Suavizado Exponencial Simple

Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble

Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble
- 3 Suavizamiento Exponencial Triple

Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble
- 3 Suavizamiento Exponencial Triple
- 4 Método Theta

Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble
- 3 Suavizamiento Exponencial Triple
- 4 Método Theta
- 5 ETS Framework

Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble
- 3 Suavizamiento Exponencial Triple
- 4 Método Theta
- 5 ETS Framework
- 6 Pronóstico con Prophet

Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble
- 3 Suavizamiento Exponencial Triple
- 4 Método Theta
- 5 ETS Framework
- 6 Pronóstico con Prophet

¿Por Qué Suavizado Exponencial?

Problema con Promedios Móviles

Los promedios móviles simples dan **igual peso** a todas las observaciones, incluyendo las antiguas.

Promedio Móvil

Pesos: $\frac{1}{n}, \frac{1}{n}, \dots, \frac{1}{n}$

Todos iguales $\Rightarrow$ inflexible

Suavizado Exponencial

Pesos decrecen:

$\alpha(1 - \alpha)^0, \alpha(1 - \alpha)^1, \dots$

Observaciones recientes pesan más

Simple Exponential Smoothing (SES)

Ecuación Recursiva

$$\hat{y}_{t+1} = \alpha y_t + (1 - \alpha)\hat{y}_t$$

donde $0 < \alpha < 1$ es el **parámetro de suavizamiento**.

Interpretación Alternativa

Promedio ponderado exponencial: $\hat{y}_{t+1} = \alpha[y_t + (1 - \alpha)y_{t-1} + (1 - \alpha)^2 y_{t-2} + \dots]$


Efecto del Parámetro Alpha

α Bajo (0.1)

- Pronóstico muy suave
- Lento para responder
- Ideal para datos ruidosos
- Lag notable

α Alto (0.9)

- Pronóstico reactivo
- Sigue de cerca los datos
- Riesgo de sobreajuste
- Menos suavizamiento



Limitaciones del Suavizamiento Simple

Lo que SES Captura

Solo: Nivel (media local) de la serie

Lo que SES NO Captura

- Tendencias
- Patrones estacionales
- Cambios en volatilidad

Problema Crítico

Cuando hay tendencia, SES genera pronósticos **planos (horizontales)** que NO capturan el cambio futuro esperado. Necesitaremos métodos que capturen tendencia (**Doble**), estacionalidad (**Triple**) y drift (**Theta**).

Familia de Métodos Exponenciales

Progresión de Complejidad

Método	Nivel	Tendencia	Estacional	Parámetros
Simple (SES)	✓			α
Doble (Holt)	✓	✓		α, β
Triple (HW)	✓	✓	✓	α, β, γ
Theta	✓	lineal		α

Simple

Nivel

Doble

Nivel + Tendencia

Triple

Nivel + Tendencia
+ Estacionalidad

Theta

SES + Drift
lineal

Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble**
- 3 Suavizamiento Exponencial Triple
- 4 Método Theta
- 5 ETS Framework
- 6 Pronóstico con Prophet

Double Exponential Smoothing (Holt)

Extensión de SES

Extiende SES agregando un componente de **tendencia** (slope).

Descomposición

$$y_t = \ell_t + b_t + \epsilon_t$$

- ℓ_t : nivel (local mean)
- b_t : tendencia (slope)
- ϵ_t : error aleatorio

Casos de Uso Ideal

- Series con tendencia clara
- Sin estacionalidad regular
- Ejemplos: ventas crecientes, temperatura anual, PIB

Double Exponential: Ecuaciones de Actualización

Componente de Nivel

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

Combina observación actual con tendencia previa.

Componente de Tendencia

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

Suaviza cambios en el nivel.

Pronóstico a Horizonte h

$$\hat{y}_{t+h} = \ell_t + h \cdot b_t$$

Proyecta tendencia constante hacia el futuro.

Double Exponential: Parámetros

Alpha (α) – Nivel

- Bajo ($\approx 0,1$): nivel cambia lentamente
- Alto ($\approx 0,9$): nivel responde rápido

Similar a SES

Beta (β) – Tendencia

- Bajo ($\approx 0,01$): tendencia suave
- Alto ($\approx 0,3$): tendencia reactiva

Nuevo en Holt

Regla Típica

$\beta \ll \alpha$ (la tendencia cambia más lentamente que el nivel)

Recomendación: $\alpha \in [0,1, 0,3]$, $\beta \in [0,01, 0,1]$

Atenuación de Tendencia (Trend Damping)


Problema: Tendencia se Perpetúa

Sin amortiguación, la tendencia crece indefinidamente generando pronósticos irrealistas.

Solución: Holt Damped

$$\hat{y}_{t+h} = \ell_t + (\phi + \phi^2 + \dots + \phi^h)b_t$$

$0 < \phi < 1$ es el factor de amortiguación (ej. $\phi = 0,98$).



Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble
- 3 Suavizamiento Exponencial Triple**
- 4 Método Theta
- 5 ETS Framework
- 6 Pronóstico con Prophet

Triple Exponential Smoothing (Holt-Winters)

Extensión Completa

Extiende Holt agregando un componente **estacional** (seasonal).

Descomposición Triple

$$y_t = \ell_t + b_t + s_t + \epsilon_t$$

- ℓ_t : nivel
- b_t : tendencia
- s_t : componente estacional
- ϵ_t : error aleatorio

Aplicaciones Reales


- Ventas mensuales (crecimiento + temporada navideña)
- Consumo eléctrico (tendencia + ciclos diarios/anuales)
- Turismo (crecimiento + temporadas altas)
- Demanda de helados (tendencia + verano)

Holt-Winters: Aditivo vs Multiplicativo

ADITIVO – Amplitud Constante

$$y_t = \ell_t + b_t + s_t + \epsilon_t$$


Fluctuaciones tienen magnitud **fija**



Fluctuaciones ± 2 constantes

MULTIPLICATIVO – Amplitud Proporcional

$$y_t = (\ell_t + b_t) \cdot s_t + \epsilon_t$$



Fluctuaciones proporcionales (10–20 %)

Cuándo Usar

Desviaciones con amplitud fija respecto a tendencia

Cuándo Usar

Amplitud aumenta con el crecimiento

Holt-Winters Aditivo: Ecuaciones

Actualización del Nivel

$$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

Observación desestacionalizada $\Rightarrow$ nivel

Actualización de Tendencia

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

Cambio en nivel $\Rightarrow$ tendencia suavizada

Actualización de Estacionalidad

$$s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$$

Desviación suavizada del patrón

Pronóstico

$$\hat{y}_{t+h} = \ell_t + h \cdot b_t + s_{t-m+h}$$

m = periodo estacional (12 mensual, 4 trimestral)

Holt-Winters: Parámetros

Alpha (α)

- **Rango:** (0, 1)
- **Significado:** Nivel
- **Recomendado:** [0,01, 0,3]

Beta (β)

- **Rango:** (0, 1)
- **Significado:** Tendencia
- **Recomendado:** [0,01, 0,1]

Gamma (γ)

- **Rango:** (0, 1)
- **Significado:** Estacionalidad
- **Recomendado:** [0,01, 0,1]

Importante

Estos parámetros se **optimizan automáticamente** usando criterios como AIC/BIC.

Inicialización de Componentes

Nivel Inicial (ℓ_0)

Promedio de la primera estación:

$$\ell_0 = \frac{1}{m} \sum_{i=1}^m y_i$$

Intuición: valor típico del primer ciclo.

Tendencia Inicial (b_0)

Pendiente promedio entre dos estaciones:

$$b_0 = \frac{1}{m} \sum_{i=1}^m \frac{y_{m+i} - y_i}{m}$$

Intuición: cuánto crece la serie por paso.

Estacionalidad Inicial (s_i)

- **Aditivo:** $s_i = y_i - \ell_0$
- **Multiplicativo:**

$$s_i = \frac{y_i}{\ell_0}$$

En la Práctica

statsforecast y statsmodels calculan estos valores automáticamente. No necesitas especificarlos manualmente.

Optimización de Parámetros

Objetivo

Minimizar el error de predicción en datos históricos (ajuste).

Restricciones Típicas

$\alpha, \beta, \gamma \in [0,01, 0,99]$ para estabilidad numérica


Criterios de Error

- **SSE:** $\sum_{t=1}^n (y_t - \hat{y}_t)^2$ — suma de cuadrados
- **AIC:** $2k + n \ln(\text{SSE}/n)$ — penaliza parámetros extras
- **BIC:** $k \ln(n) + n \ln(\text{SSE}/n)$ — penalización más severa

Métodos de Optimización

- **Grid search:** Rápido pero incompleto
- **No-lineales:** Lentos pero precisos
- **Hybrid:** Combinación de ambos

Resumen Visual: Simple vs Doble vs Triple



Elección Según Datos

- **SES:** Sin tendencia, sin estacionalidad (datos estables)
- **Holt:** Con tendencia clara, sin estacionalidad
- **Holt-Winters (Triple):** Con tendencia Y estacionalidad

Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble
- 3 Suavizamiento Exponencial Triple
- 4 Método Theta**
- 5 ETS Framework
- 6 Pronóstico con Prophet

El Método Theta: SES con Drift

Idea y contexto

- Propuesto por Assimakopoulos y Nikolopoulos (2000).
- **Ganó la competencia M3**: 3003 series reales.
- Lección central: modelos simples y bien diseñados pueden competir con modelos complejos.

Dos señales que se combinan

1. **Tendencia global** estimada por regresión:

$$T_t = c + b_0(t - 1)$$

2. **Memoria local** por suavizado exponencial:

$$\hat{X}_t = (1 - \alpha)T_t + \alpha\hat{X}_{t-1}$$

Mensaje clave

Theta = tendencia lineal global + SES local: pronósticos suaves, con drift de largo plazo.

Theta vs SES vs Holt

¿Qué lo diferencia de Holt?

Holt (Doble): la tendencia se *actualiza* en cada paso mediante suavizado exponencial β . Captura cambios de tendencia local.

Theta: la tendencia es una *única recta global* estimada al inicio por OLS. Es más rígida pero más robusta con series cortas.

Ventajas de Theta

- Un solo parámetro (α) a optimizar
- Muy rápido computacionalmente
- Excelente en series cortas y ruidosas
- Ganador históricamente en benchmarks

Limitaciones de Theta

- Tendencia lineal únicamente
- No captura estacionalidad (se elimina antes)
- No modela cambios de tendencia en el tiempo

Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble
- 3 Suavizamiento Exponencial Triple
- 4 Método Theta
- 5 ETS Framework**
- 6 Pronóstico con Prophet

ETS Framework: Taxonomía

Nomenclatura Sistemática

ETS = Error, Trend, Seasonal → **Estructura:** ETS(E, T, S)

Error (E)

- **A:** Aditivo
- **M:** Multiplicativo

Trend (T)

- **N:** None
- **A:** Aditivo
- **Ad:** Amortiguado

Seasonal (S)

- **N:** None
- **A:** Aditivo
- **M:** Multiplicativo

Ejemplos Comunes

- **ETS(A,N,N):** SES simple (solo nivel)
- **ETS(A,A,N):** Holt aditivo (nivel + tendencia)
- **ETS(A,A,A):** Holt-Winters aditivo completo

Combinaciones Válidas en ETS

Restricciones

No todas las combinaciones son válidas (evitar inestabilidad numérica):

- Error Multiplicativo + componentes Multiplicativos: muy inestable
- Trend Amortiguado solo con error aditivo

Combinaciones Estables Típicas

- **Simples:** $ETS(A,N,N)$, $ETS(M,N,N)$ — sin componentes
- **Tendencia:** $ETS(A,A,N)$, $ETS(M,A,N)$ — solo crecimiento
- **Estacionales:** $ETS(A,A,A)$, $ETS(M,A,A)$ — completos
- **Amortiguados:** $ETS(A,Ad,A)$ — Holt damped aditivo

Selección Automática de Modelos ETS

Criterio de Información AIC

$$AIC = 2k + 2 \ln \left(\frac{SSE}{n} \right) \quad \text{donde } k \text{ es el número de parámetros.}$$

Proceso Automático

1. Estimar los ≈ 30 modelos ETS válidos
2. Calcular AIC para cada uno
3. Seleccionar modelo con AIC **MÍNIMO**
4. Validar en datos de prueba (test set)

Ventajas

- Objetivo (sin opinión)
- Reproducible
- No necesita análisis de ACF/PACF
- Rápido computacionalmente

ETS vs SARIMA: Comparación Directa

ETS (Exponential Smoothing)

Ventajas:

- Modelo intuitivo y flexible
- Parámetros interpretables
- Pocos parámetros (1–3)
- Optimización muy rápida
- Excelente para estacionalidad

Cuándo usar:

- Patrón estacional claro
- Múltiples series en paralelo
- Necesitas rapidez y escalabilidad

SARIMA (ARIMA Estacional)


Ventajas:

- Base estadística sólida (Box-Jenkins)
- Más parámetros (hasta 6–7)
- Análisis ACF/PACF detallado
- Mejor para patrones complejos

Cuándo usar:

- Patrón muy complejo
- Series cortas ($n < 100$)
- Estudios estadísticos rigurosos

Árbol de Decisión: Cuándo Usar Cada Método



Recomendación Práctica

Probar **ETS/Theta** (velocidad) + **SARIMA** (precisión) → Comparar con AIC/BIC en validación cruzada

Tabla Comparativa: Métodos Completos

Método	Tendencia	Estacional	Paráms.	Velocidad	Flexibilidad
AR/MA	No	No	p, q	Rápido	Baja
ARIMA	Sí (diff)	No	p, d, q	Rápido	Media
SARIMA	Sí	Sí	p, d, q, P, D, Q	Moderado	Alta
SES	No	No	1	Muy rápido	Muy baja
Theta	Lineal	No	1	Muy rápido	Baja
Holt	Sí	No	2	Muy rápido	Baja
HW-Add	Sí	Sí	3	Muy rápido	Alta
HW-Mul	Sí	Sí	3	Muy rápido	Alta

Para Problemas Prácticos

Comenzar con **ETS/Theta** (velocidad) → validar con **SARIMA** (solidez) → elegir el mejor con AIC/BIC

Implementación con el Ecosistema Nixtla

Una API para muchos modelos

El formato del curso es siempre `unique_id | ds | y`. Con `StatsForecast` se entrenan varios modelos clásicos en paralelo.

```
1 from statsforecast import StatsForecast
2 from statsforecast.models import AutoETS, Theta, HoltWinters
3
4 sf = StatsForecast(
5     models=[AutoETS(season_length=12),
6               Theta(season_length=12),
7               HoltWinters(season_length=12, error_type='A')],
8     freq='ME', n_jobs=-1
9 )
10 forecast_df = sf.forecast(df=df_train, h=12)
```

Entrada

`unique_id`: serie
`ds`: fecha
`y`: valor

Modelos

AutoETS: selecciona ETS
Theta: baseline robusto
HoltWinters: estacional

Salida

`forecast_df` contiene los pronósticos para cada `unique_id` y horizonte.

Agenda

- 1 Suavizado Exponencial Simple
- 2 Suavizamiento Exponencial Doble
- 3 Suavizamiento Exponencial Triple
- 4 Método Theta
- 5 ETS Framework
- 6 Pronóstico con Prophet

De Holt-Winters a Prophet

La misma filosofía de descomposición

Ambos son modelos aditivos; cambian la forma de representar tendencia, estacionalidad y eventos.

Holt-Winters

$$\hat{y}_{t+h} = \ell_t + hb_t + s_{t-m+h}$$

- Tendencia lineal o amortiguada.
- Estacionalidad con periodo fijo m .
- No modela feriados ni eventos.
- Parámetros: α, β, γ .

Prophet

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

- Tendencia lineal o logística con change-points.
- Estacionalidad con series de Fourier.
- Feriados y eventos arbitrarios.
- Diseñado para escala masiva.

Prophet: Tendencia y Estacionalidad

Modelo aditivo

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

$g(t)$ – Tendencia

Lineal con changepoints:

$$g(t) = (k + \mathbf{a}(t)^\top \boldsymbol{\delta})t$$

- k : crecimiento base.
- $\boldsymbol{\delta}$: cambios de pendiente.
- Alternativa: crecimiento logístico con capacidad L .

$s(t)$ – Estacionalidad

Series de Fourier:

$$s(t) = \sum_{n=1}^N \left(a_n \cos \frac{2\pi nt}{P} + b_n \sin \frac{2\pi nt}{P} \right)$$

- P : periodo anual, semanal, diario, etc.
- N : controla la flexibilidad del patrón.
- Permite varias estacionalidades simultáneas.

Prophet: Eventos y Ajuste

$h(t)$ – Feriados y eventos

Regresores indicadores:

$$h(t) = \mathbf{Z}(t)\boldsymbol{\kappa}$$

- $\mathbf{Z}(t)$: matriz de ocurrencia de eventos.
- $\boldsymbol{\kappa}$: magnitud estimada del efecto.
- Ejemplos: Navidad, Black Friday, campañas.

Optimización

Prophet estima los parámetros en Stan y selecciona changepoints candidatos de forma automática.

changepoints $\subset$ primer 80 % de la serie

- BFGS para el ajuste inicial.
- Priors controlan suavidad y flexibilidad.
- Resultado: componentes interpretables.

Lectura del modelo

Tendencia + estacionalidades + eventos = pronóstico explicable.

Prophet: Implementación Básica

Nota: Prophet usa su propio formato (ds | y)

A diferencia de statsforecast, Prophet no usa unique_id. Se ajusta una serie a la vez.

```
1 from prophet import Prophet
2
3 model = Prophet(
4     changepoint_prior_scale=0.05, # rigidez de la tendencia (default 0.05)
5     seasonality_mode='additive', # o 'multiplicative'
6     yearly_seasonality=True,
7     weekly_seasonality=True,
8 )
9 model.fit(df_train) # df_train: columnas ds | y
0 future = model.make_future_dataframe(periods=365)
1 forecast = model.predict(future)
```

Fortalezas

Feriados arbitrarios, múltiple estacionalidad, intervalos de incertidumbre, robusto a datos faltantes.

Limitaciones

No es el mejor en benchmarks universales. Funciona mejor con series largas (> 2 temporadas) y estacionalidad fuerte.

HW vs Prophet vs Theta: Mapa de Uso

Característica	SES	Holt-Winters	Theta	Prophet
Tendencia lineal	×	✓	✓	✓
Tendencia no lineal	×	×	×	✓
Estacionalidad fija	×	✓	×	✓
Estacionalidad múltiple	×	×	×	✓
Feriados / Eventos	×	×	×	✓
Ecosistema Nixtla	✓	✓	✓	×
Velocidad (miles series)	Muy alta	Alta	Muy alta	Baja
Núm. parámetros	1	3	1	> 10

* Prophet tiene adaptaciones en NeuralProphet (ecosistema PyTorch).

Regla práctica

Theta/ETS para benchmarks rápidos y múltiples series → **HW** si hay estacionalidad clara → **Prophet** si hay feriados, changepoints o múltiple estacionalidad.

Referencias

-  Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5th ed.). Wiley.
-  Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press.
-  Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts.
-  Assimakopoulos, V., & Nikolopoulos, K. (2000). The Theta model: a decomposition approach to forecasting. *International Journal of Forecasting*, 16(4), 521–530.
-  Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37–45.
-  Auffarth, B. (2021). *Machine Learning for Time-Series with Python*. Packt Publishing.