



MAESTRÍA EN INTELIGENCIA ARTIFICIAL Y CIENCIA DE DATOS

PRONÓSTICO DE SERIES TEMPORALES CON IA

INFORME DE ANÁLISIS DE SERIES TEMPORALES CASOS SEMANALES DE DENGUE EN CALI

PROFESOR:

SERGIO ALEJANDRO CANTILLO LUNA

ALEJANDRO MENESES
MARKO DAVID GARCÍA MUÑOZ

Mayo, 2026

TABLA DE CONTENIDO

- TABLA DE CONTENIDO..... 2
- 1. INTRODUCCIÓN..... 3
- 2. CARGA DE DATOS Y FORMATO NIXTLA..... 3
 - Observaciones de la serie original..... 4
- 3. CALIDAD DE DATOS..... 5
 - 3.1 Valores faltantes e imputación..... 5
 - 3.2 Partición temporal..... 5
- 4. OUTLIERS, CAMBIOS DE RÉGIMEN Y DESCOMPOSICIÓN STL..... 5
 - 4.1 Detección de outliers..... 5
 - 4.2 Cambios de régimen..... 6
 - 4.3 Descomposición STL..... 7
- 5. AUTOCORRELACIÓN, ESTACIONARIEDAD Y LJUNG-BOX..... 9
 - 5.1 Análisis de autocorrelación..... 9
 - 5.2 Pruebas de estacionariedad..... 9
 - 5.3 Test de Ljung-Box..... 9
- 6. MODELOS BASELINE Y VALIDACIÓN TEMPORAL..... 10
- 7. DIAGNÓSTICO DE RESIDUOS DEL MEJOR BASELINE..... 11
- 8. TIME SERIES CROSS-VALIDATION..... 12
- 9. CONCLUSIONES..... 12

1. INTRODUCCIÓN

La generación de información en salud pública requiere transformar registros operativos en evidencia analítica útil para la toma de decisiones. En enfermedades transmitidas por vectores, como el dengue, la vigilancia temporal es especialmente relevante porque los brotes no ocurren como eventos aislados: suelen presentar persistencia semanal, cambios de nivel, variabilidad estacional y dependencia de condiciones externas. Este informe presenta el proceso desarrollado en el notebook de análisis de series temporales para casos de dengue en Cali. El objetivo es construir una serie semanal regular, evaluar su calidad, caracterizar su estructura temporal y establecer modelos baseline de pronóstico que sirvan como punto de comparación antes de avanzar hacia modelos más complejos.

La base utilizada contiene 61.933 registros individuales entre 2010-01-03 y 2024-03-29. Después de la agregación e imputación controlada, la serie final contiene 744 semanas y 62.248 casos acumulados. La media semanal es 83.67 casos, mientras que la mediana es 51.00, lo cual anticipa una distribución asimétrica con brotes epidémicos de alta magnitud.

Indicador	Valor
Registros originales	61.933
Semanas finales	744.0
Casos totales	62.248
Media semanal	83.67
Mediana semanal	51.0
Desviación estándar	97.2
Máximo semanal	573.0

Tabla 1. Resumen descriptivo de la serie semanal.

2. CARGA DE DATOS Y FORMATO NIXTLA

Los datos originales corresponden a registros individuales de casos notificados por fecha. Para analizarlos como serie temporal, cada fecha de notificación se asignó al lunes de su semana epidemiológica ISO y luego se agruparon los registros por semana. El resultado se estructuró en formato Nixtla: “**unique_id**”, “**ds**” y “**y**”.

Esta transformación es metodológicamente importante porque convierte una base transaccional en una secuencia temporal regular. La columna **ds** representa la fecha de la semana y **y** el número de casos observados. Esta estructura facilita el uso de modelos de pronóstico, validación temporal y evaluación reproducible.

Número de Casos de Dengue por Semana




Figura 1. Serie semanal de casos de dengue y outliers globales por IQR.

Observaciones de la serie original

1. **Brotes epidémicos recurrentes:** Se observan varios picos grandes de casos: 2010, 2013 a 2014, 2016, 2020, 2023 a 2024. Esto indica ciclos epidémicos recurrentes muy típicos del dengue.
2. **Estacionalidad evidente:** Los brotes no ocurren aleatoriamente. Parecen repetirse en ciertos períodos del tiempo. Esto sugiere fuerte influencia de otros factores como lluvias, temperatura, humedad, dinámica vectorial. Es decir se observa un componente estacional importante.
3. **Cambios de régimen:** La serie alterna entre periodos endémicos con pocos casos y periodos epidémicos con crecimiento explosivo. Eso indica comportamiento multi-régimen muy típico de sistemas infecciosos complejos.
4. **No linealidad:** Los aumentos no son graduales. Los brotes aparecen abruptamente, aceleradamente, de forma explosiva. Esto nos indica dinámica no lineal y posible comportamiento aleatorio o altamente sensible a condiciones externas.
5. **Heteroscedasticidad:** La variabilidad cambia mucho en el tiempo, en años tranquilos se observa poca dispersión y estabilidad. En epidemias se observa gran volatilidad y cambios extremos.
6. **Persistencia temporal:** Los brotes duran varias semanas, por lo que no son picos aislados. Esto se relaciona con la memoria temporal epidemiológica que coincide con el comportamiento típico de transmisión infecciosa.
7. **Ruptura estructural reciente (2023–2024):** El brote más reciente parece más intenso que varios anteriores y además crece rápidamente, alcanza niveles muy altos. Esto podría indicar nuevo comportamiento epidemiológico o cambio estructural.
8. **Posibles problemas al final de la serie:** La caída abrupta cercana a 2024 podría deberse a retraso de reporte, truncamiento de datos, semanas incompletas.

El mapa de calor año-semana permite observar la concentración temporal de los brotes. La intensidad no se distribuye de forma homogénea: algunos años concentran semanas con conteos muy altos, lo que sugiere que el proceso tiene fases epidemiológicas diferenciadas.




Figura 2. Mapa de calor año-semana de casos de dengue.

Semana	Casos
2010-02-15	573
2010-02-22	543
2023-12-25	537
2010-02-08	504
2010-03-01	475
2023-12-18	466
2010-03-08	451
2023-12-11	442

Tabla 2. Semanas con mayor número de casos observados.

3. CALIDAD DE DATOS

3.1 Valores faltantes e imputación

Antes de modelar, se verificó la continuidad del calendario semanal. Este paso evita que saltos de calendario sean interpretados como dinámica epidemiológica real. La serie observada contenía semanas faltantes al final del horizonte, posteriormente se completó el calendario semanal y se imputaron los valores faltantes usando la media estacional calculada únicamente con el conjunto de entrenamiento.

Las semanas faltantes detectadas fueron: **2024-02-26**, **2024-03-11**, **2024-03-18**. La imputación se realizó después del split temporal para evitar fuga de información desde el período de prueba hacia el entrenamiento.

Estado	Observaciones	Semanas esperadas	Fechas faltantes	NaN en y
Serie observada	741	744	3	0
Calendario completo	744	744	0	0

Tabla 3. Diagnóstico de continuidad temporal e imputación.

3.2 Partición temporal

La partición temporal respeta el orden cronológico de la serie. El entrenamiento incluye las observaciones anteriores a 2020 y el conjunto de prueba cubre el período reciente, que contiene alta variabilidad epidemiológica. Esta división es más específica que una partición aleatoria típica, pero es válida para un problema de pronóstico de esta naturaleza.


Segmento	Observaciones	Inicio	Fin
Entrenamiento	523	2009-12-28	2019-12-30
Prueba	221	2020-01-06	2024-03-25

Tabla 4. Partición temporal de entrenamiento y prueba.

4. OUTLIERS, CAMBIOS DE RÉGIMEN Y DESCOMPOSICIÓN STL

4.1 Detección de outliers

El método IQR global detectó 57 semanas extremas, con límite superior aproximado de 242.00 casos. El Z-score detectó 17 semanas, mientras que el IQR condicionado por mes detectó 56 semanas.



Los outliers detectados por el método IQR no parecen ser errores de datos, sino eventos epidemiológicos reales de alta importancia.

4.1.1. Brotes epidémicos

Los puntos rojos aparecen concentrados en los picos de la serie:

- 2010
- 2013
- 2016
- 2020
- 2023 - 2024

Esto indica que representan semanas de transmisión excepcionalmente alta, es decir brotes epidémicos severos y no simples anomalías estadísticas.

En dengue esto es completamente esperado.

Estos outliers suelen estar asociados a cambios climáticos extremos, fenómeno de El Niño / La Niña, aumento de lluvias, aumento de temperatura, aparición de nuevos serotipos, disminución

de inmunidad poblacional, fallas en campañas de control vectorial, saturación hospitalaria, subregistro previo seguido de corrección.

Es decir que representan cambios reales del proceso epidemiológico, no errores de medición.

4.1.2. Alta concentración en ciertos años

Especialmente fuerte en 2010 y 2023 al 2024

Esto sugiere que esos años fueron años epidémicos extraordinarios y probablemente deberían analizarse por separado.

Pueden incluso justificar:

- Segmentación del modelo.
- Análisis por régimen epidemiológico.
- Modelos con change points.

En conclusión es importante dejar los outliers para el futuro modelo predictivo.

Método	Criterio	Semanas detectadas
IQR global	$y < -118.00$ o $y > 242.00$	57
Z-score	$ z > 3$	17
IQR por mes	IQR dentro de cada mes	56

Tabla 5. Resumen de métodos de detección de outliers.

4.2 Cambios de régimen

La comparación entre subperíodos muestra una media semanal de **95.86** casos en el primer tramo y **71.47** en el segundo. **La prueba t rechaza igualdad de medias** al 5%, mientras que **Levene no rechaza igualdad de varianzas**. Esto sugiere cambio estructural en nivel pero persistencia de una volatilidad elevada en ambos períodos.




Figura 3. Media móvil y desviación estándar móvil de la serie.

Prueba	Hipótesis nula	p-valor	Lectura
Levene	Varianzas iguales	0.092	No rechaza al 5%
t de medias	Medias iguales	0.0006	Rechaza al 5%

Tabla 6. Pruebas estadísticas de cambio de régimen.

Se observan claramente varios cambios de régimen, los cuales se podrían clasificar de la siguiente manera:

- **Régimen de alta transmisión:** Cuando la media móvil sube fuertemente los periodos son los siguientes: 2010, 2013 al 2014, 2016, 2020, 2023 al 2024, estos corresponden a brotes epidémicos.
- **Régimen de baja transmisión:** Cuando la media móvil permanece cerca de cero, en este caso, los periodos son los siguientes: 2011 al 2012, 2017 al 2019. Esto representa periodos endémicos controlados con baja circulación viral.

Adicionalmente se realizaron los test de Lavene y T, evidenciando un cambio estructural en los periodos:

4.3 Descomposición STL

La descomposición STL muestra que la serie de dengue está dominada por brotes fuertes más que por una tendencia suave. En la serie original se observan picos marcados en 2010, 2016, 2020 y finales de 2023, separados por periodos de baja transmisión, después la tendencia cambia lentamente: baja hasta aproximadamente 2019 y luego vuelve a subir hacia 2023-2024.

Descomposición STL — periodo estacional = 208 semanas




Figura 4. Descomposición STL con período estacional de 208 semanas.

La estacionalidad con período de 208 semanas captura parte importante de los picos, lo que sugiere una señal multianual cercana a cuatro años. Aun así, no es una estacionalidad perfectamente regular, porque los brotes cambian en intensidad y momento y algunos ocurren a los 3 años aproximadamente.

El residuo conserva desviaciones fuertes, especialmente en 2016, 2020 y comienzos de 2024. Esto indica que tendencia y estacionalidad **no explican completamente la dinámica**, sobre todo cuando hay cambios bruscos.

En resumen, la STL confirma que existe estructura temporal aprovechable, pero también que el dengue no sigue un ciclo simple. Los modelos puramente estacionales pueden servir como referencia, aunque probablemente fallen ante brotes irregulares o cambios rápidos de nivel.

5. AUTOCORRELACIÓN, ESTACIONARIEDAD Y LJUNG-BOX

5.1 Análisis de autocorrelación

La ACF confirma memoria temporal fuerte. El rezago 1 presenta autocorrelación de 0.9543, el rezago 4 de 0.8296 y el rezago 8 de 0.6421. Esto implica que los casos de una semana dependen de forma importante del pasado reciente, comportamiento consistente con una enfermedad infecciosa de transmisión persistente.




Figura 5. Función de autocorrelación de la serie semanal.

Se observa que los primeros lags tienen valores muy cercanos a 1. Esto significa que los casos actuales dependen fuertemente del pasado reciente

Es decir, si esta semana hay muchos casos, la siguiente semana probablemente también.

Este comportamiento es esperado en dengue.

Se observa un decaimiento lento. La autocorrelación disminuye lentamente no cae bruscamente permanece significativa hasta un lag de 25. Esto indica una fuerte persistencia temporal y también posible no estacionariedad, porque en series estacionarias la ACF suele caer mucho más rápido en este caso no ocurre eso.

No parece ruido blanco, si fuera ruido blanco $ACF(k) \approx 0$ para casi todos los lags.

Pero aquí casi todos los lags son significativos por encima del IC 95%, entonces la serie tiene estructura temporal real no es aleatoria.

5.2 Pruebas de estacionariedad

Las pruebas ADF y KPSS se interpretan de forma complementaria. ADF evalúa raíz unitaria y KPSS evalúa estacionariedad alrededor de un nivel. En los datos analizados, ambas pruebas son compatibles con estacionariedad estadística. Sin embargo, esta conclusión debe leerse con matices pues se debe tener en cuenta los brotes y cambios de régimen observados visualmente.

Prueba	Hipótesis nula	p-valor	Conclusión
ADF	Raíz unitaria	0.00	Estacionaria
KPSS	Estacionariedad	0.1	Compatible con estacionariedad

Tabla 7. Pruebas de estacionariedad ADF y KPSS.

5.3 Test de Ljung-Box

El test de Ljung-Box rechaza la hipótesis de ausencia conjunta de autocorrelación en todos los rezagos evaluados. Por tanto, la serie no se comporta como ruido blanco y contiene estructura temporal explotable por medio de modelos de pronóstico.

Lag	p-valor
1.0	0.0
6.0	0.0
12.0	0.0
18.0	0.0
24.0	0.0
30.0	0.0

Tabla 8. Test de Ljung-Box sobre la serie original.

Figura 6. p-valores Ljung-Box por rezago.

6. MODELOS BASELINE Y VALIDACIÓN TEMPORAL

Se evaluaron cuatro modelos baseline con **statsforecast**: **Naive**, **SeasonalNaive**, **WindowAverage** y **RandomWalkWithDrift**. El parámetro estacional usado en el proyecto para SeasonalNaive fue 208 semanas. Estos modelos no buscan ser la solución final sino una línea base interpretable contra la cual comparar modelos futuros. El período de prueba incluye años recientes con brotes y cambios de nivel, por lo cual la evaluación es exigente, un buen baseline debe capturar el nivel general sin sobreajustarse a un episodio específico.




Figura 7. Pronósticos baseline frente a valores reales del conjunto de prueba.

Métrica	Naive	SeasonalNaive	WindowAverage	RWD
mae	111.99	81.83	99.93	130.19
rmse	123.14	121.82	115.62	140.11
smape	0.4556	0.5901	0.4285	0.4829
mase	8.8949	6.4995	7.9369	10.34

Tabla 9. Métricas de desempeño de modelos baseline.

Comparación de Métricas por Modelo
Barra dorada = mejor modelo en esa métrica




Figura 8. Comparación visual de métricas de desempeño.

Por MAE y MASE, el mejor baseline fue SeasonalNaive, con MAE de 81.83. Por RMSE y sMAPE, el mejor fue WindowAverage, lo que confirma que la selección del modelo depende de la métrica priorizada. Para vigilancia epidemiológica, conviene revisar no solo el error promedio, sino también el comportamiento durante semanas de brote.

7. DIAGNÓSTICO DE RESIDUOS DEL MEJOR BASELINE

Aunque **SeasonalNaive** obtuvo el mejor desempeño entre los modelos baseline según el MAE, el análisis de residuos evidencia que sus errores no son completamente aleatorios. La media residual de **46.32** indica un sesgo positivo, lo cual sugiere que el modelo tiende a subestimar los valores observados. Asimismo, la desviación estándar de **112.93** refleja una alta variabilidad en los errores, especialmente en periodos con cambios abruptos en la serie (picos epidemiológicos). La gráfica temporal de residuos muestra episodios prolongados de errores positivos y algunos valores extremos, mientras que la ACF evidencia autocorrelación significativa en varios rezagos. Esto implica que el modelo aún deja estructura temporal sin explicar.

Diagnóstico de Residuos — SeasonalNaive
Tiempo, distribución y autocorrelación remanente




Figura 9. Diagnóstico de residuos del modelo SeasonalNaive.

Lag	Estadístico Q	p-valor
1.0	175.3498	0.00
6.0	634.2403	0.00
12.0	688.8371	0.00

Tabla 10. Ljung-Box sobre residuos del mejor baseline por MAE.

Este diagnóstico cierra el ciclo de modelado baseline: aunque el modelo seleccionado es competitivo dentro del conjunto probado, sus residuos no se comportan como ruido blanco. Por tanto, existe margen estadístico y práctico para modelos con mayor capacidad dinámica (ej: SARIMA).

8. TIME SERIES CROSS-VALIDATION

Además del holdout temporal, se aplicó validación cruzada rolling-origin. Este procedimiento evalúa los modelos en varios cortes temporales, manteniendo siempre la dirección del tiempo. En series epidemiológicas esto es clave porque un único periodo de prueba puede favorecer accidentalmente al modelo que mejor captura un brote específico.

Time Series Cross-Validation — SeasonalNaive



Figura 10. Validación cruzada temporal para SeasonalNaive.

La validación cruzada permite interpretar la estabilidad del desempeño. Si el rendimiento varía ampliamente entre cortes, esa variabilidad debe reportarse como incertidumbre del sistema de pronóstico y no ocultarse detrás de una única métrica promedio.

9. CONCLUSIONES

- 1. La serie es apta para modelado temporal:** porque puede organizarse como una secuencia semanal regular en formato Nixtla. La calidad temporal básica es suficiente para entrenar y evaluar modelos, siempre que la imputación se haga sin fuga de información.
- 2. El dengue en Cali muestra dinámica epidémica y no ruido aleatorio:** La alta autocorrelación de corto plazo confirma persistencia: los niveles de una semana dependen fuertemente de las semanas anteriores. Esto justifica el uso de modelos de series temporales.
- 3. Los valores extremos son epidemiológicamente relevantes:** Los picos de 2010, 2020 y 2023 no deben tratarse automáticamente como errores. Representan fases críticas del

fenómeno y son precisamente los eventos que un modelo predictivo debería aprender a anticipar.

4. Los baselines son necesarios, pero insuficientes: Modelos como Naive, SeasonalNaive, WindowAverage y RandomWalkWithDrift entregan una referencia clara de desempeño. Sin embargo, su dificultad para capturar cambios bruscos de régimen muestra que el problema requiere modelos con mayor capacidad dinámica.

5. La evaluación debe priorizar estabilidad temporal: Un modelo puede ganar en un holdout específico y perder consistencia en validación rolling-origin. En la práctica, para una aplicación de un modelo en salud pública, la robustez ante distintos períodos es tan importante como el error promedio.

6. Siguiendo paso a considerar: comparar estos baselines contra modelos como SARIMA/SARIMAX o modelos de machine learning con rezagos y, además, tener en cuenta variables climáticas.